# R grunnkurs

ASLAUG HURLEN FOSS, ANITA CECILIE DAL

OG SAMER ALTINAWI

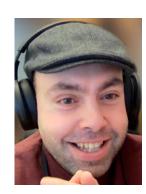


# Presentasjon av kursholdere











### Målet med kurset

- Bli kjent programmet R
- Bli litt kjent med Jupiter og hente kode fra Github
- Lese inn data
- Behandler data
- Lage tabeller og oppsummere
- Lage figurer



## Agenda

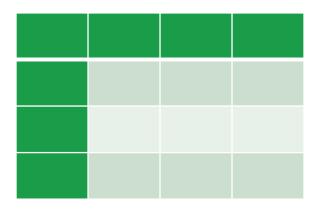
- 10.00-10.20 Introduksjon til R
- 10.20-10.40 Øvelse: Jupiter og Github
- 10.40-11.00 Tall, tekst, liste og datasett
- 11.00-11.30 Øvelse med objekter
- 11.30-12.00 Lunsj i kantina

- 12.00-12.30 Bearbeiding av data
- 12.30-13.00 Øvelser
- 13.00-13.30 Koble og grafikk
- 13.30-14.00 Øvelse



# Mitt møte med SAS - kultursjokk

#### **Datasett**



Log

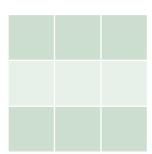
Tekst, tekst, tekst

### Objekter

Verdier

Vektor-lister







### **Hvorfor R**

- Godt språk for nybegynnere ..... og forskere
- Utviklet for statistikk
- God grafikk
- Basis + «pakker» med funksjoner
- Egen konferanse for r i statistikkproduksjon!

The R Project - The Use of R in Official Statistics - uRos2022





### awesome-official-statistics-software









**Nederland** Dataeditering



# Internasjonalt: awesome-official-statistics-software

- Liste med programvare for offisiell statistikk
- Kategorisert etter prosessmodellen GSBPM
- Listen blir vedlikeholdt av Nederland
- Ukentlig sjekk av oppdatering
- Internasjonale retningslinjer
- Gjenbruk er bra!

Design frame and sample (GSBPM 2.1)

R package SamplingStrata. Optimal Stratification of Sampling Frames for Multipurpose Sampling Surveys.

CRAN 1.0.4 – a year ago license EUPL

R package R2BEAT. Multistage Sampling Allocation and PSU Selection.

Design variable descriptions (GSBPM 2.2)

GitLab no releases found last commit december license MIT License
 Excel SDMX\_Matrix\_Generator. Excel-based visual SDMX artefact authoring tool which generates SDMX-ML for upload into an SDMX repository such as a registry. By OECD.

#### Sampling (GSBPM 4.1)

- CRAN 2.9 2 years ago license GPL (>= 2)
  - R package sampling. Several algorithms for drawing survey samples, including a variety of unequal probability sampling designs (high entropy, systematic, Rao-Sampford, etc.), and calibrating design weights.
- CRAN 4.0 3 years ago license GPL (>= 2)

R package surveyplanning. Tools for sample survey planning, including sample size calculation, estimation of expected precision for the estimates of totals, and calculation of optimal sample size allocation.

CRAN 1.2.8 – 4 months ago license GPL (>= 2)

R package PracTools. Functions and datasets related to Valliant, Dever, and Kreuter (2018 2nd ed), *Practical Tools for Designing and Weighting Survey Samples*.



# Miljø for å kjøre R

- Jupiter godt egnet for enkle ting
- Rstudio den «vanlige» verktøyet for R.
- Muligheter i Rstudio versus Jupiter
  - Lett å se på data og objekter, pakker og figurer i Rstudio
  - Lett å bygge enkle dashboard og analyser i pdf
  - Bygge pakker som er viktig funksjon for metode og forskningsavdelingen

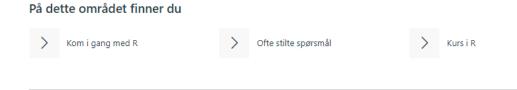


### R i SSB

### R-produktteam

- Testet workbench ble for dyrt
- Rstudio på ny R-server jobbes med nå
- Rstudio i Sky?
- Felles funksjoner i R

#### R - ressurser og kompetansebygging





#### Produksjonssonen

- Uttrekk fra Dynarev i R ( dynarev\_uttrekk )
- Laste opp data til Statistikkbanken ( statbank\_lasting )
- R pakkehåndtering med renv ( create\_dependencies , install.packages , restore , snapshot , ssb\_library )

#### DAPLA

- Lese inn og skrive filer på DAPLA ( read\_SSB , write\_SSB , gcs\_bucket , list.files )
- R pakkehåndtering med renv ( create\_dependencies , install.packages , restore , snapshot , ssb\_library )



### Metodebibliotek i SSB

- Metodebiblioteket er SSBs bibliotek
   for statistiske metoder
- Alle funksjoner er og testet i metodeseksjonen og er i dag i bruk i minst én produksjonsprosess.





#### Metodebiblioteket functions

Feb. 28, 2022 sklearn.svm

#### LinearSVC

Linear Support Vector
Classification. Similar to SVC
with parameter kernel='linear',
but implemented in terms of
liblinear rather than libsvm, so it
has more flexibility in the choice
of penalties and loss functions
and should scale better to large
numbers of samples.

PYTHON IMPUTATION CLASSIFICATION

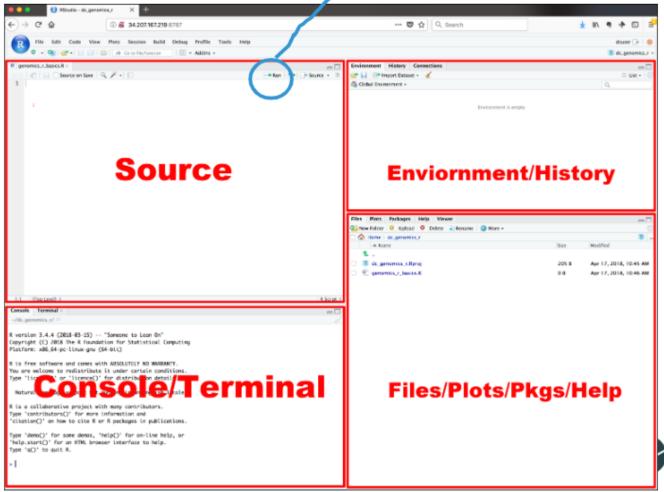
#### CATEGORIES

Articles (7)
classification (2)
confidentiality (4)
dataediting (2)
imputation (2)
python (1)
R (6)

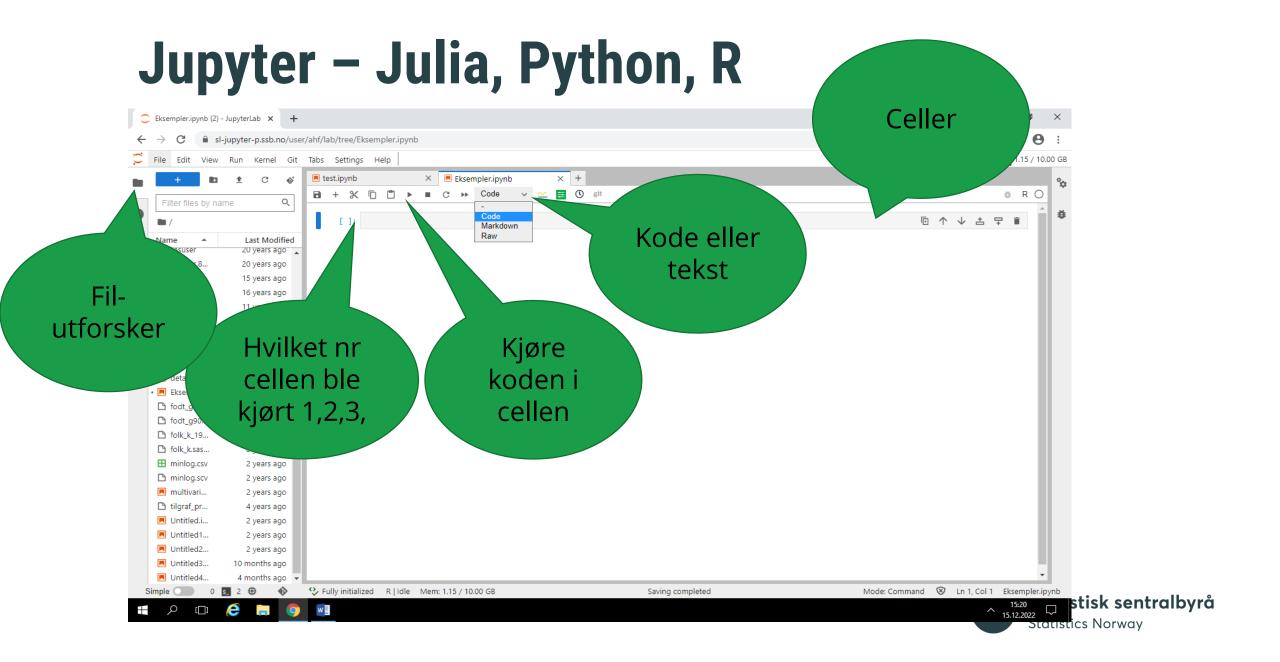




Kjøre-knappen (eller ctrl + enter)



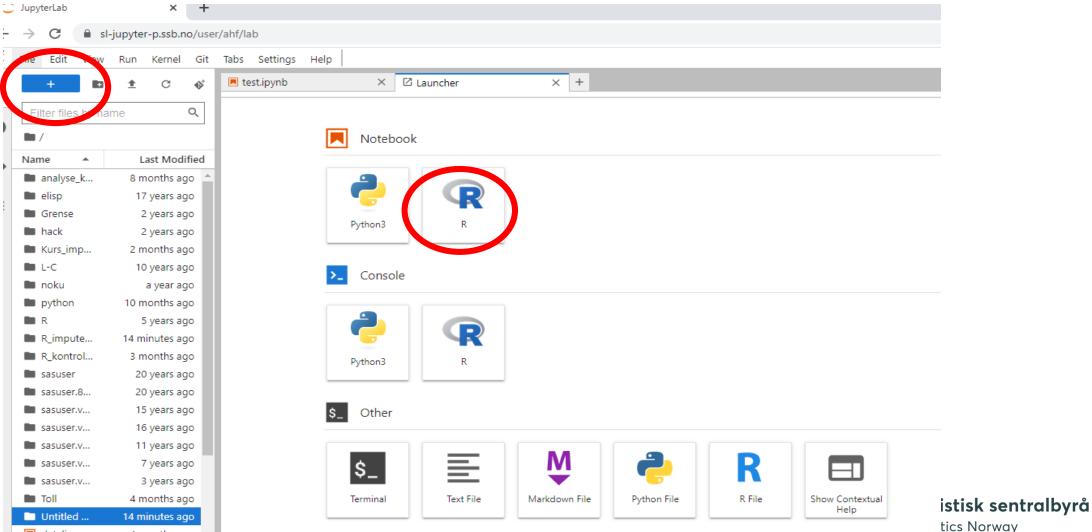




# Jupyter – Julia, Python, R

4 months ago

detaljom...



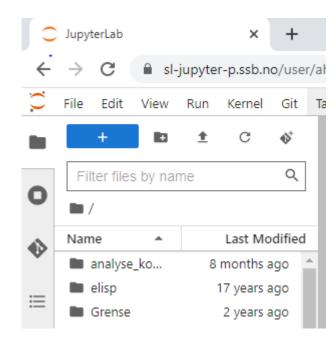
# Jupyter - Julia, Python, R



Terminal og kjerne

Git

Innhold





### Hva er markdown?

- Markdown er en enkel syntaks som formaterer tekst som overskrifter, lister, fet skrift og så videre.
- Mest brukte kommandoer:

```
• # - tittel (## - overskrift)
```

- \*\*tekst\*\* tekst i fet skrift
- \*tekst\* tekst i kursiv skrift
- \$ x=by +e \$ matematiske formler



# Eksempel

```
# Tittel
## Overskrift
Dette er **min** tekst med formler $ y=bx+e $ og bruk av *kursiv*
```

#### Tittel

#### Overskrift

Dette er **min** tekst med formler y = bx + e og bruk av *kursiv* 

#### Analyse av statistiske kontroller i Tvinn

#### Aslaug Hurlen Foss

29 3 2022

#### Innledning

Som input kontroll har Tvinn registeret to statistiske kontollfunksjoner. Relativ priskontroll og generell priskontroll. Parametrene til disse funksjonene blir levert av SSB.

#### Data

Grunnlaget for analysen er alle varer i mengde og verdi fortollet i 2019. Datasettet inneholder omtrent 22 millioner observasjoner.

Variabler i kontrollene: \* verdi \* mengde

Grupperingsvariabler for analysen:

- Eksport/import
- Mengde og annen mengde hvilken variabel?
- · Varegrupper det kan bli brukt de to første sifre

#### Definisjon av rettet og treffsikkerhet

Antall rettet av de som er slått ut i denne kontrollen:

- Rettet 1: Behandlet i klargjøringsprosessen i SSB med kodene: Retting, Omberegning og Slettet
- Rettet 2: Endret verdi i mengde, verdi eller varenummer. Eller at varen har blitt slettet.

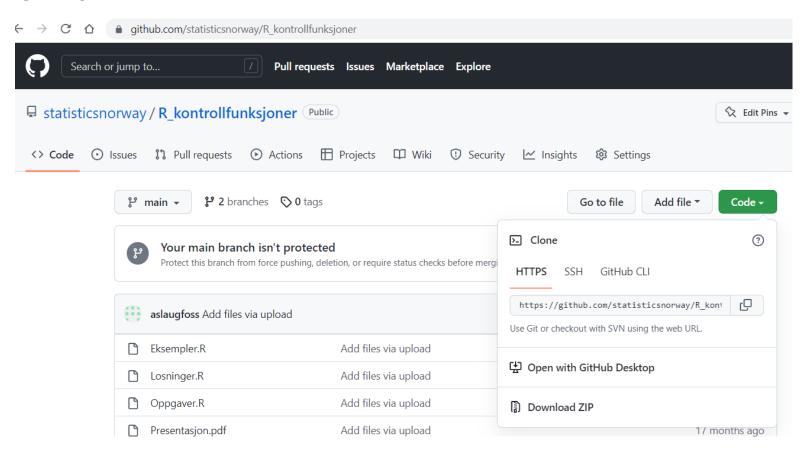
Det kan altså være at det blir rettet andre variabler som landkode og ikke verdi, mengde eller varenummer. Kontrollene som skal analyseres her er forholdet mellom verdi og mengde i de forskjellige varegruppene.

Treffsikkerhet er antall rettede verdier delt på antall vareposter som er slått ut i en kontroll, oppgitt i prosent.



### Kursmaterialet

# https://github.com/statisticsnorway/kurs-r-grunnkurs-jupyter



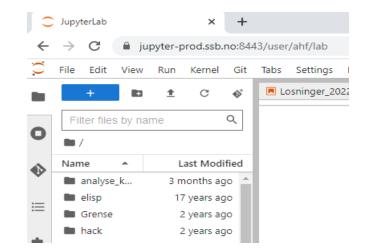


# Starte opp Jupyter i produksjonssonen

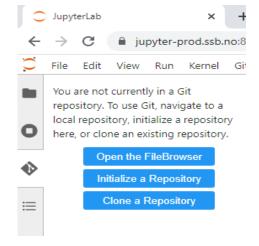
• Trykk på ikonet:

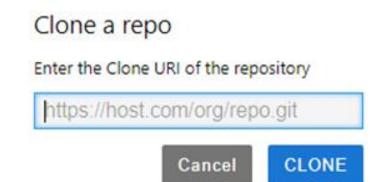


• Stå i «filutforsker»



• Trykk på Github-ikonet:





### Øvelse

- Gå til kursmaterialet på Github og kopier adressen (https://github.com/statisticsnorway/kurs-r-grunnkurs-jupyter)
- Starte Jupyter i produksjonssonen
- Klone kurset over til deg selv
- Lage en ny Notebook i R
- Lage en tekst i Markdown med overskrift og fet skrift. Lag navn på notebooken.

# Tall, tekst, liste og datasett

### R som kalkulator

• Regnestykkene kan tastes rett inn:





# Grunnfunksjoner



Alle funksjoner i R har hjelpfiler:





### Tekststrenger - streng

'Nittedal'

- Både enkel (' ') og dobbel snutter (" ") kan brukes –konsistent!
- CASE SENSITIVE

Kommune ≠ kommune

• Lim sammen med paste()

paste()

Plukk ut deler med substring()

substring(steng, start, stop)



# Objekter

- Et objekt inneholder data
- Å lage et objekt er å gi det et navn

Kommune <- 'Nittedal'

- Vi bruker <- for å allokere noe til et objekt
- Skriv ut hva innhold er ved å skrive objektnavn

Kommune

> 'Nittedal'



# Objekter

CASE SENSITIVE

- Kommune ≠ kommune
- MÅ starte med en bokstav
- Ikke mellomrom (bruk \_ )
- Forskjellige innhold: for eks. tall eller tekststreng
- Kan overskrives

Kommune <- 'Kongsvinger'



# Objekttyper

- char karakter, tekststreng
- num numerisk verdi
- date dato
- factor kategorisk bestemt nivå
- data.fram datasett



### Liste - vektorer

- Objekter inneholder flere verdier
- Bruk c() for å kombinere verdier og komma mellom
- Må være samme objekttype

c( 'Kongsvinger', 'Oslo') c(1,3,6)



## Vektorer som objekt

Gir vektorer et navn ved



• Finne lengde av vektoren ved funksjonen

length()

• For å finne ut objekttypen bruk

str()



# Logiske setninger

Sammenlign objekter ved ==

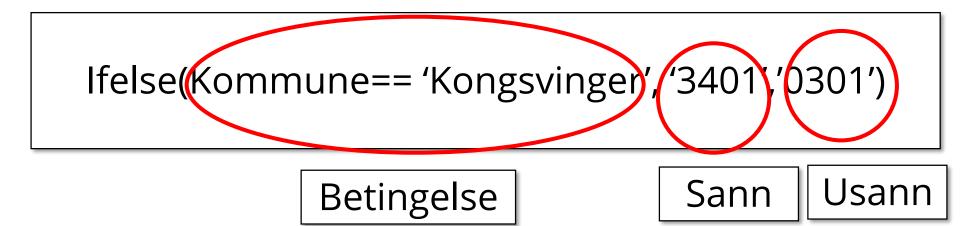
Skrives ut: TRUE/FALSE

Kode i K	Betyaning
==	Sammenlign om de er like
!=	Om de er ulike
>	Større enn
>=	Større enn eller lik
<	Mindre enn
<=	Mindre enn eller lik
%in%	er inn i

- Kan brukes på vektorer
- Bind sammen med & for og, | for eller

### Hvis eller....

• For å sammenlign og gjøre noen kan vi bruke funksjon





# Lage et datasett

- Objekt kan være et datasett (rader og koloner)
- Kombinere forskjellige type vektorer

```
data.frame()
```

```
data.frame(objekt1, objekt2)
```

```
data.frame(kolonnenavn1=c(1,2), kolonnenavn2=c("banan", "eple"))
```

# Se på datasett

- Skriv navnet på datasettet datasettet blir printet ut
- Se på de 5 første linjene av datasettet: head()



## Pakker og biblioteker

- Pakker er en «modul» samling av funksjoner
- Cran bibliotek med samling av pakker
- Hvordan bruke pakker:
  - Installering av pakker, en gang: install.packages('pakkenavn')
  - For hver gang koden kjører: library(pakkenavn)



### Les inn datasett: .csv fil

```
library(tidyverse)
                                Skilletegn = , Desimaltegn = .
read_csv()
     Sti til datasett
library(tidyverse)
read_csv2()
                                 Skilletegn = ; Desimaltegn = ,
      Sti til datasett
```



### Les inn sas fil

• VI kan lese inn sas datasett (.sas7bdat) direkte til R med haven pakken

library(haven)

read\_sas('sti til datasettet')

?read\_sas



#### Lese inn data fra statistikkbanken

- Bruk pakken PxWebApiData
- Trenger tabell nummer

```
library(PxWebApiData)
helse_bank <- ApiData(12293, KOKkommuneregion0000 = TRUE , ContentsCode =TRUE,Tid = TRUE)
dat<-helse_bank[[2]]
meta<-helse_bank[[1]]</pre>
```

• E-læringskurs: <a href="https://statisticsnorway.shinyapps.io/ApiData\_tutorial/">https://statisticsnorway.shinyapps.io/ApiData\_tutorial/</a>



#### Lese inn data fra Klass

## - database for klassifiseringer og kodelister

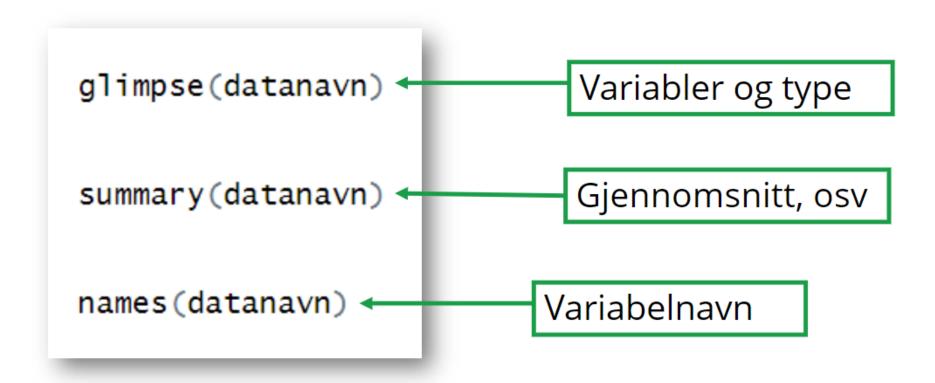
- Bruk pakken klassR
- Trenger id nummer til klassifiseringen adressen i URL

```
#Henter gyldig fylkesliste fra Klass
library(klassR)
fy_klass <- GetKlass(klass = 214, date = "2022-01-01")</pre>
```

• E-læringskurs: <a href="https://statisticsnorway.shinyapps.io/KlassR\_tutorial/">https://statisticsnorway.shinyapps.io/KlassR\_tutorial/</a>



## Ser nærmere på data





## Eksempler kjøring i R



#### Øvelse

- Oppgaver 1- 12 på filen: Oppgaver.ipynb
- Løsninger på oppgavene fins på filen: Losninger.ipynb
- Hvis det er for mange oppgaver, plukk ut det du synes er mest interessant for deg!



# Bearbeiding av datasett

## Bearbeiding med pakken «tidyverse»

- Gjør koden ryddigere effektiv og lesbar
- Pipelines «rørledning» med %>% som pipe operator

%>% - Denne operatøren vil videresende en verdi, eller resultatet av et uttrykk, til neste uttrykk.

Base R:

```
leave_house(get_dressed(get_out_of_bed(wake_up(me))))
```

#### tidyverse:

```
me %>%
  wake_up() %>%
  get_out_of_bed() %>%
  get_dressed() %>%
  leave_house()
```

## Lage nye variabler: mutate()

• Kan brukes som en del av en pipeline

```
datanavn %>%
mutate(nyvariabel = 1000)
Gir variabel et navn
```

```
datanavn %>%
mutate(nyvariabel = oldvariabel * 1000)

Gir variabel et navn

Eksisternende variabel
```

+ hva skal gjøres



## Lage nye variabler: mutate()

- Kombinere med ifelse()
- For å lagre husk <-
- Kan overskrives
- Flere variablene kan lagres samtidig (, for å skille)
- Endre variabeltype (as.character(), as.numeric())

```
datanavn %>%
  mutate(variabelnavn = as.character(variabelnavn))
```



## Velg noen rader: filter()

- For å velge ut noen rader bruker vi filter()
- Skriv logiske setning inn i parentes.
- Flere logiske setninger kan brukes sammen (skille med,)

```
datanavn %>%
  filter(condition)
```

Igjen: Ingenting lagres uten <-</li>



## Velg ut noen variabler: select()

- Brukes med pipelines
- Skriv variabelnavn i parentes
- En eller flere variabler (skille med , )
- Brukes sammen med andre funksjoner (for eks. filter())

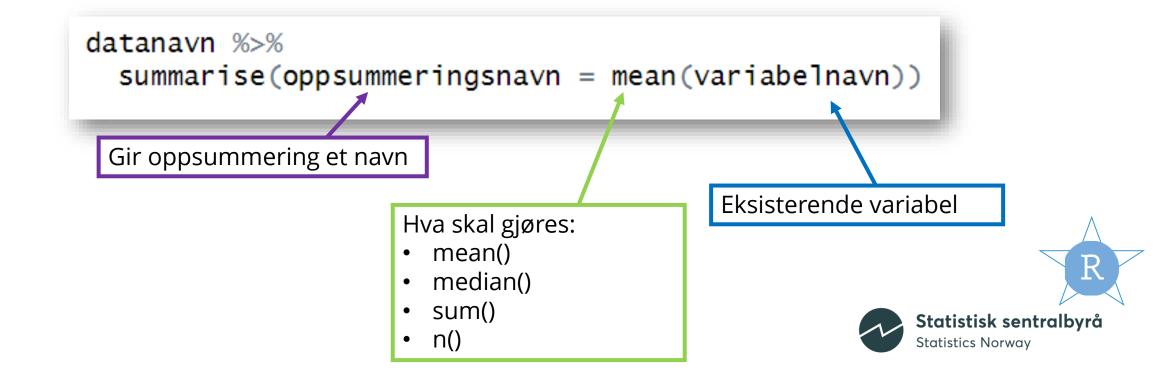
```
datanavn %>%
  filter(condition) %>%
  select(variabelnavn)
```

```
datanavn %>%
  select(variabelnavn)
```



## Oppsummering/aggregering: summarise()

• Ta oppsummering (summen, gjennomsnitt, median, antall) av en variabel med summarise()



## **Gruppering:** group\_by()

• Gjøre alle prosesser etterpå innen hver gruppe

```
datanavn %>%
  group_by(grupperingsvariabel) %>%
  summarise(oppsummeringsnavn = mean(variabelnavn))
```



## Gruppering: group\_by() og spread()

- Kombinere flere variabeler med ,
- For en 2 x 2 frekvenstabell:

```
datanavn %>%
  group_by(grupperingsvariabel1, grupperingsvaraibel2) %>%
  summarise(oppsummeringsnavn = n()) %>%
  spread(grupperingsvariabel1, oppsummeringsnavn)
```



## Endre variabelnavn: rename()

```
datanavn %>%
  rename(nyttnavn = gammeltnavn)
```



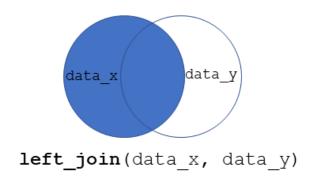
## Øvelser 3

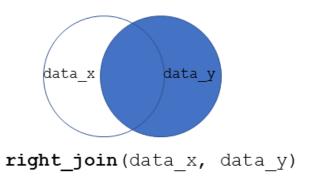
• Oppgave 13 til 18

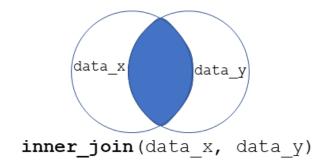


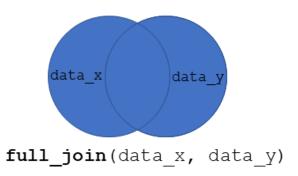
# Koble og figurer

#### **Koble to datasett**











#### **Koble to datasett**

Bruk by = for å spesifisere nøkkel variabel til å koble på

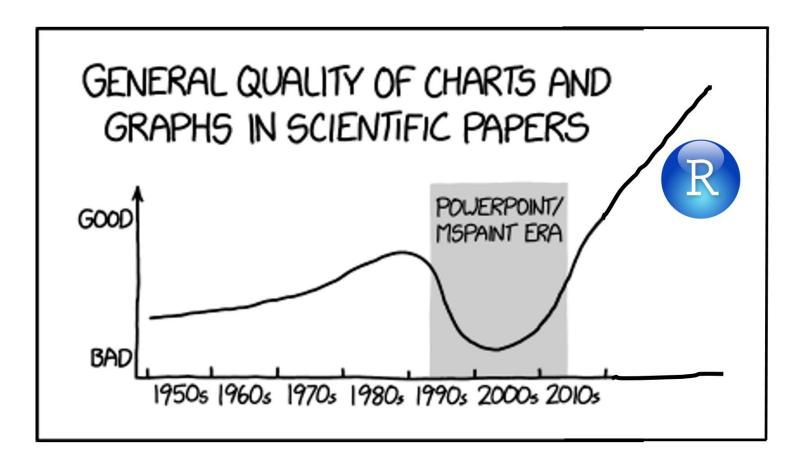
$$by = c("aar" = "year")$$

kobletdata <- left\_join(datanavn1, datanavn2, by = variabelnavn)</pre>

• Flere variabler kan brukes for å koble på (som en vektor)



## **Plotting**





## Plotting med ggplot()

- aes : aesthetics, hvilke variabler
- geom\_: hva slags figur
- **stat** : hva slags statistisk aggregat å presentere

Table 18-1 A Selection of Geoms and Associated Default Stats		
Geom	Description	Default Stat
geom_bar()	Bar chart	stat_bin()
geom_point()	Scatterplot	stat_identity()
geom_line()	Line diagram, connecting observations in order by x-value	stat_identity()
geom_boxplot	Box-and-whisker plot	stat_boxplot()
geom_path	Line diagram, connecting observations in original order	stat_identity()
geom_smooth	Add a smoothed condi- tioned mean	stat_smooth()
geom_histogram	An alias for geom_ bar() and stat_ bin()	stat_bin()

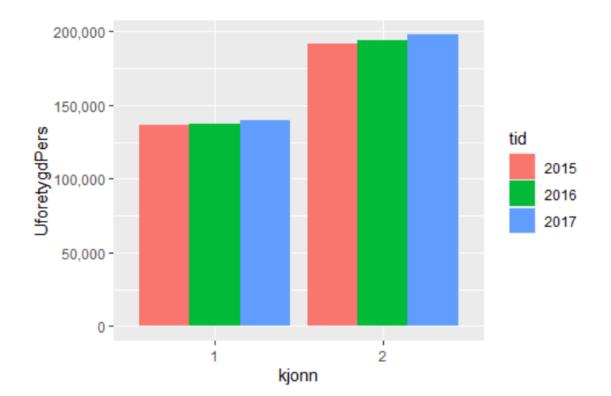
## Søylediagram

```
ggplot(aes(variabelnavn)) +
                                                       Bruke + for å legge til figurtype
     geom_bar()
                                  Spesifisere variabelen
 Spesifisere søylediagram
ggplot(aes=c(x = variabelnavn1, y = variabelnavn2)) +
  geom_bar(stat="identity")
                             Spesifisere x og y variablene
       Spesifisere å bruke verdi
                                                                  Statistisk sentralbyrå
```

Statistics Norway

## Søylediagram

- Bruk fill() i aes for å spesifisere en variabel for farge
- Kombinere med filter først





## Punktdiagram

Sammenlign to numeriske variabler

```
ggplot(aes(x = variabelnavn1, y = variabelnavn2)) +
geom_point()
```

• Legg til regresjonslinje med

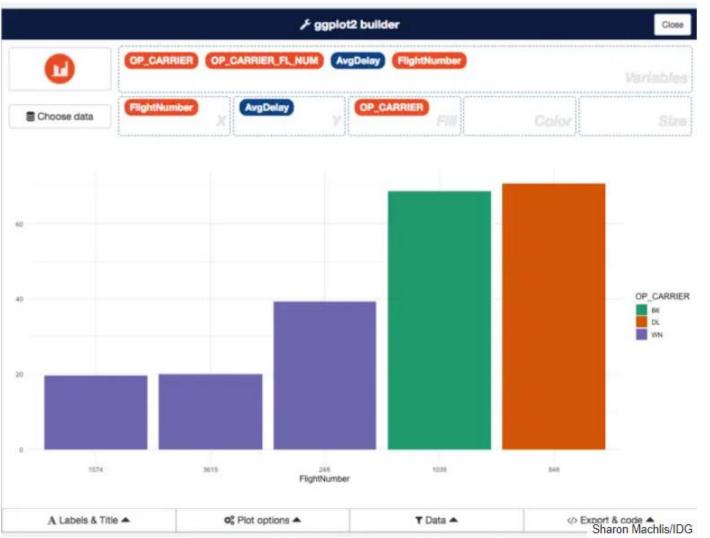
```
geom_smooth(method = "lm")
```

Farge punktene etter gruppe

```
geom_point(aes(color = varaibelnavn))
```



## Drag-and-drop ggplot med pakken esquisse



Fungerer ikke på Jupyter!



## Plotly – interaktive figurer

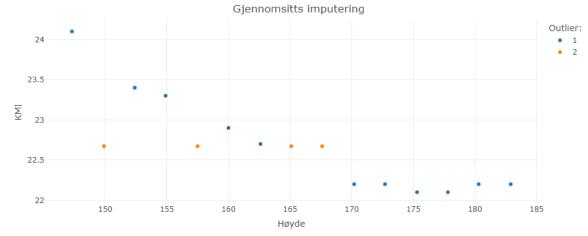
- Funksjonalitet:
  - hover få informasjon når markøren holdes over et punkt i grafen
  - Zoome
  - Selektere
- Kan omgjøre plot i ggplot til plotly



## Interaktive figurer - plotly

#### • Funksjonalitet:

- hover få informasjon når markøren holdes over et punkt i grafen
- Zoome
- Selektere
- Kan omgjøre plot i ggplot til plotly
  - library(plotly)
  - fig1<- ggplot(aes(x=variabel1, y=variabel2)) + geom\_point()
  - ggplotly(fig1)





## Øvelse 4

• Oppgaver 19- 27



## R- videregående

- Kommer i mars med Susie
- Flipped classrom

 Målsetning: Å gjøre medarbeiderne i stand til å jobbe med mer kompleks oppgaver i R og strukturere kode ved bruk av funksjoner.

#### • Innhold:

- Datasett, variabeltype og indeksering
- Loops
- Funksjoner
- Kjøring av R og python sammen



## **Oppsummering**

- Husk library()
- Les inn filer: read\_csv2() read\_sas()
- Ny variabel: mutate()
- Velg noen linje: filter()
- Aggregere/oppsummere: summarise()
- Figur: ggplot(), aes(), geom\_...()

- https://ssbno.sharepoint.com/sites
   /Kompetanseogutvikling/SitePages
   /Ressursside-om-R.aspx
- Yammer: R i SSB
- Google



# Takk!

